Fatine Kassabi

Lille, France • Mobile en France et à l'international • +33 7 74 21 63 40
fatinekassabi22@gmail.com • linkedin.com/in/fatine-kassabi • github.com/FatineKa

Data scientist diplômée d'un master en Data Science (Lille, 2026), avec deux stages en machine learning. Conçoit des modèles de bout en bout, de la modélisation bayésienne et causale aux systèmes LLM/RAG, livrés en Python testé (API, dashboards, CI). Vise un poste de Data Scientist ou ML Engineer en entreprise.

Compétences

Statistiques : inférence bayésienne, MCMC, inférence causale, uplift modeling, A/B testing
Programmation et ML : Python (pandas, NumPy, scikit-learn, LightGBM, PyTorch), SQL, R
LLM et NLP : Hugging Face Transformers, Qwen2.5, Llama 3.3, RAG, LangChain, ChromaDB, prompt engineering
Data et cloud : Snowflake, AWS (Lambda, Step Functions, SNS, S3)
Ingénierie et MLOps : FastAPI, Streamlit, Docker, Git, GitHub Actions (CI), pytest, Linux, Bash
Langues : français (C1), anglais (C1), arabe (langue maternelle)

Expériences professionnelles

Stage de fin d'études en IA : LLM, embeddings et inférence bayésienne Mars – sept. 2026
Laboratoire Paul Painlevé (Université de Lille, CNRS) *Villeneuve-d'Ascq, France*

- Réalisation d'un système de recherche sémantique bayésien retrouvant, parmi 31 114 idiomes chinois, celui qui résume le mieux un texte (vraisemblance du LLM Qwen2.5 et a priori de fréquence) ; exposé via une API FastAPI.
- Conception d'un algorithme d'échantillonnage Metropolis–Hastings guidé par les embeddings : sur le jeu de test, son premier choix retrouve celui de la loi a posteriori exacte dans 22,8 % des cas, contre 17,2 % sans guidage (hasard : 0,003 %).
- Comparaison de trois mesures de distance sur toutes les couches du modèle pour prédire l'adéquation idiome–texte : la meilleure (distance euclidienne, couche 23) préfère le bon idiome à un mauvais dans 72 % des cas (hasard : 50 %).

Stage en machine learning : descente d'échelle climatique par deep learning Mars – sept. 2025
International Water Research Institute (IWRI), Université Mohammed VI Polytechnique (UM6P) *Benguerir, Maroc*

- Développement d'un pipeline de descente d'échelle des précipitations (prétraitement, feature engineering) sur 27 ans de données climatiques (sorties du modèle LMDZ-IPSL, réanalyse ERA5), de 250 km à 35 km de résolution.
- Comparaison d'un Vision Transformer et d'un autoencodeur convolutif (PyTorch, GPU) avec des modèles Random Forest et SVM (scikit-learn) : précision point par point (RMSE, R^2) et biais spatial par maille.
- Random Forest ($R^2 = 0{,}88$), meilleur modèle de référence (baseline), s'est révélé plus performant que le Vision Transformer ($R^2 = 0{,}85$), meilleur modèle de deep learning.

Projets académiques et personnels

Modélisation uplift pour l'optimisation marketing (Criteo, 3 millions d'utilisateurs) Juin – août 2026
Projet personnel *github.com/FatineKa/retail-media-uplift*

- Développement et comparaison de quatre modèles d'uplift combinant les approches T-learner, S-learner et class transformation avec LightGBM et la régression logistique ; sélection du meilleur modèle sur un jeu de validation, puis évaluation par **courbes de Qini** sur 900 000 utilisateurs de test.
- Évaluation du gain de profit par rapport au ciblage par propension à l'aide d'un **bootstrap apparié** : à 2 % de budget, le ciblage uplift génère 3 034 $ supplémentaires, un écart toutefois non significatif sur le plan statistique.
- Déploiement d'un contrôle automatisé de la qualité des données (Snowflake, AWS Lambda) et d'un dashboard Streamlit.

Système LLM/RAG d'orientation universitaire personnalisée Janv. – mars 2026
Projet de fin d'année, Université de Lille *github.com/FatineKa/orientation-rag*

- Conception d'un pipeline RAG en deux étapes sur 3 354 formations : recherche vectorielle ChromaDB (embeddings multilingues, filtres de métadonnées extraits des requêtes et de formulaires PDF), puis génération contrainte aux formations retrouvées.
- Intégration de Llama 3.3, GPT-4o-mini et Mistral via LangChain, derrière une interface Streamlit.

Formation

Master Ingénierie statistique et numérique, parcours Data Science 2025 – 2026
Université de Lille, Faculté des Sciences et Technologies *Villeneuve-d'Ascq, France*

Master Modélisation mathématique et science des données 2023 – 2025
Université Abdelmalek Essaâdi, Faculté des Sciences et Techniques *Tanger, Maroc*

Licence en ingénierie statistique 2020 – 2023
Université Abdelmalek Essaâdi, Faculté des Sciences et Techniques *Tanger, Maroc*